

Yapay Zekâ Tabanlı Ses Sistemlerinde Gürültü Engelleme (AI-Based Noise Cancelling)

Mert Şahin
Bilgisayar Mühendisliği
Ankara Üniversitesi
Ankara, Türkiye
mert096488@gmail.com

Özetçe—Bu çalışmanın ana odağı, yapay zeka tabanlı ses sistemlerinde etkili bir gürültü engelleme çözümü geliştirmektir. Projenin temel amacı, arka plan gürültülerini filtreleyerek operasyonel ortamlarda iletişim kalitesini artırmaktır. Bu doğrultuda, ses iyileştirme alanında öne çıkan ve difüzyon modellerindeki koşul bilgisinin entegrasyonu sorununu çözen DOSE modeli tercih edilmiştir. Modelin performansı, özel olarak hazırlanmış bir Türkçe konuşma veri seti kullanılarak eğitilmiş ve değerlendirilmiştir.

Keywords—Yapay Zeka, Gürültü Engelleme, Ses İyileştirme, DOSE

I. GİRİŞ

Bu proje, kulaklık ve mikrofon gibi ses sistemlerinde değişen koşullara adaptif, yüksek kaliteli iletişim sağlamak amacıyla yapay zekâ tabanlı konuşma geliştirme (SE) yöntemlerine odaklanmaktadır. Günümüzde, sesle kontrol edilen cihazlar, telekonferans sistemleri ve uzaktan eğitim platformları gibi birçok alanda konuşma anlaşılabilirliği büyük önem taşıırken, arka plan gürültüsü sistemlerin performansını düşürmektedir. Geleneksel gürültü azaltma yöntemleri bu çeşitli gürültü türlerine karşı yetersiz kalmaktadır.

Bu zorluğun üstesinden gelmek için, DOSE adı verilen bir yöntem kullanılmıştır[1]. Bu yöntem, difüzyon olasılıksal modellerine (DDPM) koşul bilgisini daha etkili bir şekilde dahil ederek gürültü azaltma sorununa yeni bir yaklaşım getirmektedir. Projenin en önemli yeniliği, Türkçe konuşma verilerine özel olarak odaklanmasıdır. Mevcut modellerin Türkçe kaynak eksikliğini gidermek amacıyla, temiz Türkçe ses kayıtlarına çeşitli gürültü türleri eklenerek sentetik bir veri seti oluşturulmuştur. Bu veri seti, gürültülü ortamlarda Türkçe konuşmayı daha anlaşılır hale getirmeyi hedefleyen modelin eğitiminde kullanılmıştır.

II. LİTERATÜR TARAMASI

Bu projenin metodolojisi ve model seçimi, konuşma geliştirme alanındaki güncel çalışmaların incelenmesiyle belirlenmiştir. Bu kapsamda, proje için ilham kaynağı olan ve farklı yaklaşımları temsil eden iki temel konuya odaklanılmıştır: kullanılan modelin seçimi ve veri setinin oluşturulma yöntemi.

A. Sentetik Veri Seti Oluşturma Yöntemleri

Yapay zekâ projelerinde modelin başarısı, büyük ölçüde eğitim veri setinin kalitesine ve çeşitliliğine bağlıdır. Gerçek gürültülü ortam kayıtlarını toplamak hem maliyetli hem de zaman alıcı bir süreçtir. Bu sebeplerle, literatürdeki birçok

çalışma sentetik veri seti oluşturma yöntemini benimsemektedir.

Bu yaklaşım, temiz konuşma kayıtları üzerine kontrollü bir şekilde farklı gürültü sinyallerini eklenmesine dayanır. Bu yöntem, VoiceBank-DEMAND[10] ve EARS-WHAM[2] gibi popüler veri setlerinin oluşturulmasında da kullanılmıştır. Makaleler, gürültü ekleme işlemini ITU-T P.56[3,13] standardına uygun olarak, konuşmanın aktif seviyelerini baz alarak gürültünün ölçeklendirilmesini sağlamaktadır. Bu sayede, daha doğal gürültülü ortamlar simüle edilmektedir. Bunun yanı sıra, ITU-R BS.1770[4] gibi standartlara uygun olarak, algısal olarak da daha anlamlı bir ölçekleme sağlayan Loudness K-weighted relative to Full Scale (LKFS)[2] metriği kullanılarak sesiz bölgelerin hesaplamadan çıkarılması ve daha gerçekçi bir SNR değeri elde edilmesi gibi ileri yöntemler de bulunmaktadır. Proje, Türkçe veri setini oluştururken, bu alanda kabul görmüş hem ITU-T P.56 hem de LKFS gibi standart yaklaşımlardan yararlanmıştır.

B. Model Mimarisi Seçimi ve DOSE Yaklaşımı

Konuşma iyileştirme alanında, literatürdeki çalışmalar geleneksel yöntemlerden (spektral çıkarma, Wiener filtreleme) giderek derin öğrenme tabanlı modellere yönelmiştir. Derin öğrenme modelleri arasında da deterministik (CNN, RNN, LSTM tabanlı) ve üretken (generative) yaklaşımlar öne çıkmaktadır. Deterministik modeller gürültüyü etkili bir şekilde azaltabilirken, bazen konuşmanın doğallığını ve ince ayrıntılarını kaybetme eğiliminde olabilmektedir.

Son dönemde, difüzyon olasılıksal modelleri (DDPM) gibi üretken yaklaşımlar, yüksek kaliteli ses üretme yetenekleri sayesinde konuşma iyileştirme alanında büyük ilgi görmüştür[5,6]. Ancak bu modellerde koşul bilgisinin etkili bir şekilde entegre edilmesi önemli bir zorluk teşkil etmektedir[7,8,9]. Bu zorluk, modelin gürültülü sesi temizlerken referans alacağı bilgileri doğru kullanmasını engellemektedir.

Bu bağlamda, Xinchu Zhang vd. (2023) tarafından yayımlanan "DOSE: Diffusion Dropout with Adaptive Prior for Speech Enhancement" başlıklı makale, bu zorluklara yenilikçi bir çözüm sunmasıyla projemizin ana motivasyon kaynağı olmuştur. Bu çalışma, difüzyon modellerinde sıkça karşılaşılan genelleme sorununu ve konuşmanın aşırı temizlenerek doğallığını kaybetmesi sorununu çözmeyi amaçlamaktadır. Makalede, difüzyon modellerine "dropout" ve uyarlanabilir bir önsel (adaptive prior) tekniğini birleştiren DOSE adlı yenilikçi bir çerçeve önerilmektedir [1].

Method	Year	Efficiency	Dataset	STOI(%) [†]	PESQ [†]	CSIG [†]	CBAK [†]	COVL [†]
Unprocessed	–	–	–	92.1	1.97	3.35	2.44	2.63
DiffWave	2021	1 step (dis)	–	93.3	2.51	3.72	3.27	3.11
DiffuSE	2021	6 steps	VB	93.5 ^{+0.20}	2.39 ^{+0.12}	3.71 ^{+0.01}	3.04 ^{+0.23}	3.03 ^{+0.08}
CDiffuSE	2022	6 steps	–	93.7 ^{+0.40}	2.43 ^{+0.03}	3.77 ^{+0.02}	3.09 ^{+0.18}	3.09 ^{+0.01}
SGMSE	2022	50 steps	–	93.3 ^{+0.00}	2.34 ^{+0.17}	3.69 ^{+0.03}	2.90 ^{+0.37}	3.00 ^{+0.11}
DR-DiffuSE	2023	6 steps	–	92.9 ^{+0.08}	2.50 ^{+0.01}	3.68 ^{+0.02}	3.27 ^{+0.06}	3.08 ^{+0.03}
DOSE	–	2 steps	–	93.6 ^{+0.30}	2.56 ^{+0.05}	3.83 ^{+0.11}	3.27 ^{+0.00}	3.19 ^{+0.08}
Unprocessed	–	–	–	71.5	1.21	2.18	1.97	1.62
DiffWave	2021	1 step (dis)	–	72.3	1.22	2.21	1.95	1.63
DiffuSE	2021	6 steps	CHIME-4	83.7 ^{+1.14}	1.59 ^{+0.36}	2.91 ^{+0.70}	2.19 ^{+0.24}	2.19 ^{+0.56}
CDiffuSE	2022	6 steps	–	82.8 ^{+0.09}	1.58 ^{+0.01}	2.88 ^{+0.01}	2.15 ^{+0.01}	2.18 ^{+0.01}
SGMSE	2022	50 steps	–	84.5 ^{+2.22}	1.57 ^{+0.31}	2.92 ^{+0.71}	2.18 ^{+0.23}	2.18 ^{+0.52}
DR-DiffuSE	2023	6 steps	–	77.6 ^{+0.09}	1.29 ^{+0.01}	2.40 ^{+0.02}	2.04 ^{+0.00}	1.78 ^{+0.01}
DOSE	–	2 steps	–	86.6 ^{+4.43}	1.52 ^{+0.50}	2.71 ^{+0.91}	2.15 ^{+0.01}	2.06 ^{+0.43}

Tablo 1 : Farklı difüzyon iyileştirme yöntemlerinin karşılaştırması^[1]

Tablo 1’de gösterildiği gibi, DOSE modelinin mevcut difüzyon tabanlı modellerle karşılaştırmalı performans analizi, projemiz için model seçiminde belirleyici olmuştur.

Bu makale hakkında daha detaylı teknik bilgilere Tablo 2 ulaşabilirsiniz.

Makale İsmi:	DOSE : Diffusion Dropout with Adaptive Prior for Speech Enhancement
Yayın yılı:	2023
Yayınlağı Dergi/Konferans:	Advances in Neural Information Processing Systems, 36
Atıf Sayısı:	24
Ele Alınan Problem:	Bu makale, difüzyon modellerinin konuşma iyileştirme genelme ve asiri temizleme problemleri ele alınmaktadır.
Kullanılan Veri Seti (Belirtilmişse):	Voicebank-DEMAND[10] ve WSJO-CHIME4
Kullanılan Yaklaşımlar ve Algoritmalar:	Bu makale, konuşma iyileştirmede difüzyon modellerinin karşılaştığı genelleme ve aşırı temizlenme sorunlarını ele almaktadır. Bu zorlukların üstesinden gelmek için, difüzyon modellerinde "dropout" ve uyarlanabilir önseli birleştiren DOSE (Diffusion Dropout with Adaptive Prior for Speech Enhancement) adlı bir çerçeve önerilmektedir. DOSE, koşul bilgisini örnekleme sürecine daha etkin bir şekilde dahil ederek, Voicebank-DEMAND ve WSJO-CHIME4 gibi veri setleri üzerinde yapılan testlerde mevcut modellerden daha doğal ve iyi genellenebilen iyileştirilmiş konuşma üretme yeteneği sergilemektedir.
Performans Değerlendirilmesi:	Eğitilen modelin performansı, literatürde yaygın olarak kullanılan objektif ölçütler olan Konuşma Kalitesinin Algısal Değerlendirmesi (PESQ), Kısa Süreli Objektif Anlaşılabilirlik (STOI), Segmental Sinyal-Gürültü Oranı (SSNR), Konuşma Sinyali Bozulmasının Ortalama Görüş Puanı(MOS) Tahmini(CSIG), Arka Plan Gürültüsünün Rahatsız Ediciliğinin MOS Tahmini (CBAK), Genel Etkinin MOS Tahmini (COVL)
Makalenin Eksik ve Geliştirilebilir Noktalarının Değerlendirilmesi:	Makalede doğrudan "Future Works" başlığı altında bir bölüm bulunmamaktadır. Ancak, yapılan çalışmadaki önemli bir eksiklik olarak, kullanılan veri setlerinin (Voicebank-DEMAND ve WSJO-CHIME4) ağırlıklı olarak İngilizce

	olması ve modelin farklı dillerdeki performansının detaylı olarak incelenmemesi gösterilebilir. Bu durum, DOSE modelinin genellenebilirliğini ve farklı dil ortamlarındaki uygulanabilirliğini kısıtlamaktadır.
Makalenin Proje Kapsamında Değerlendirilmesi:	DOSE makalesi, projemizin gürültü engelleme sürecinde kullanılacak temel bir referanstır. Makale, DOSE'un "dropout" ve "uyarlanabilir önsel" mekanizmalarıyla koşul bilgisini etkin kullanmasını ve başarılı performansını göstererek bize sağlam bir metodolojik zemin sunar.

Tablo 2 : Makale inceleme tablosu

III. METODOLOJİ

A. Veri Seti Toplama ve Ön İşleme

Projenin başarısı için yüksek kaliteli ve çeşitli veri setlerinin kullanımı kritik öneme sahiptir. Bu bağlamda, temiz konuşma verisi olarak Hugging Face platformu üzerinden erişilen issai/Turkish_Speech_Corpus[11] veri seti kullanılmıştır. Bu set, Institute of Smart Systems and Artificial Intelligence (ISSAI) tarafından oluşturulmuş olup, toplam 186.171 ses dosyasından oluşmakta ve 218,2 saatlik bir toplam uzunluğa sahiptir. Bu veri setinin tercih edilmesinin temel nedeni, projenin yerel dil üzerine odaklanması ve modelin Türkçe’ye özgü fonetik özelliklerini öğrenmesini sağlamasıdır.

Bu veri setinin teknik özellikleri, Tablo 3’te gösterilen istatistiksel özetle incelenmiştir. Yapılan analizde, veri setinin minimum dosya süresinin 1 saniyenin altında olduğu tespit edilmiştir. Bu tür kısa süreli ses dosyaları, modelin öğrenme sürecinde gürültü engelleme için yeterli bağlamsal bilgi sağlamadığı ve eğitim performansını olumsuz etkileme potansiyeli taşıdığı için veri setinden çıkarılmıştır.

İstatistik	Süre (sn)	Örnekleme Hızı (Hz)	Kanal Sayısı	Maksimum Genlik
count	186170.0	186170.0	186170.0	186170.0
mean	4.220043	16000.0	1.0	0.418394
std	1.700804	0.0	0.0	0.201846
min	0.170000	16000.0	1.0	0.002319
25%	3.160000	16000.0	1.0	0.265450
50%	4.180000	16000.0	1.0	0.367554
75%	5.140000	16000.0	1.0	0.520447
max	27.159000	16000.0	1.0	1.000000

Tablo 3: Turkish_Speech_Corpus veri setinin özellikleri

Gürültü verileri için DEMAND (Diverse environments Multichannel Acoustic Noise Database)[12] veri setinden faydalanılmıştır. DEMAND veri seti çeşitli iç ve dış ortamlardan elde edilmiş gerçek dünya gürültü kayıtları içermektedir. Bu set, toplamda 22,67 saat uzunluğunda olup, ev (mutfak, banyo), ofis, kamu alanları (kafe, restoran), araç içi ve dış ortamlar (trafik, park) gibi 17 farklı ortamdan, her biri için 16 adet ses dosyası içermektedir. Bu veri setinin kullanımı, modelin yalnızca belirli gürültü tiplerini değil, aynı zamanda farklı akustik ortamların karakteristik özelliklerini de öğrenmesi sağlamış, böylece gerçek hayattaki

çeşitli gürültü senaryolarına karşı daha iyi genelleme yapma yeteneği kazandırmıştır. Projede kullanılan DEMAND veri setinin temel teknik özelliklerini Tablo 4’ te özetlenmiştir.

İstatistik	Süre (sn)	Örneklem Hızı (Hz)	Kanal Sayısı	Maksimum Genlik
count	272.0	272.0	272.0	272.0
mean	300.004	16000.0	1.0	0.241642
std	5.69482e-14	0.0	0.0	0.264542
min	300.004	16000.0	1.0	0.012512
25%	300.004	16000.0	1.0	0.056679
50%	300.004	16000.0	1.0	0.165465
75%	300.004	16000.0	1.0	0.285393
max	300.004	16000.0	1.0	1.000000

Tablo 4: DEMAD veri setinin özellikleri

B. Sentetik Veri Seti Oluşturma

Modelin eğitimi için iki farklı yaklaşımla sentetik olarak gürültülendirilmiş veri setleri oluşturulmuştur. Bu yaklaşım, modelin farklı ses seviyeleri ve algısal dinamikler üzerindeki performansını değerlendirmeyi amaçlamıştır.


- **LKFS (Loudness, K-weighted, relative to full scale) Metodu :** Bu yöntemde, temiz konuşma verisi ile gürültü verisi, LKFS standardına göre algısal olarak dengelenerek birleştirilmiştir. Bu sayede, insan kulağının gürültü algısına daha yakın bir sentetik veri seti elde edilmiştir.
- **P.56 (ITU-T P.56) Metodu :** Bu yöntem ise, uluslararası bir telekomünikasyon standardı olan P.56’ya göre ses seviyelerinin ölçülerek birleştirilmesini temel almıştır. Bu yaklaşım, gürültü engelleme işleminin daha standartlaştırılmış bir ölçümlemesini sağlamıştır.

Birleştirme aşamasında, her iki veri seti için SNR değeri belirlenen sınırlar içerisinde rastgele seçilmiştir. Bu randomizasyon, modelin geniş bir gürültü seviyesi aralığına karşı dayanıklı olmasını sağlamak için yapılmıştır. Eğitim verisi için -5 dB ile 15 dB arasında rastgele SNR değerleri kullanılırken test ve doğrulama verisi için -2.5 dB ile 17.5 dB arasında bir aralık seçilmiştir[2]. Eğitim ve test verilerinde farklı SNR aralıkları kullanılması, modelin eğitildiği veri dağılımının dışındaki gürültü seviyelerine karşı genelleme yeteneğinin daha gerçekçi bir şekilde ölçülmesini sağlamıştır.

C. Model Mimarisi


Bu projenin temelini, Google tarafından geliştirilen DiffWave[6] mimarisini temel alan, gürültü engelleme için uyarlanmış bir difüzyon tabanlı sinir ağı mimarisi oluşturmaktadır. Modelin genel işlem akışını Şekil 1’de gösterilmiştir.

Model, giriş verisi olarak gürültülü ses dalga formunu kullanır. İsteğe bağlı olarak, bu giriş verisine karşılık olarak gelen mel-spektrogramı da dahil edilebilir. Bu koşullu yaklaşım, modelin yalnızca ham ses dalga formuna değil, aynı zamanda frekans-zaman domainindeki bilgilere de erişerek gürültü engelleme performansını artırmasını sağlar.



Şekil 1: Model yapısı

Mimarinin özü, sinyalin derinlemesine işlenmesi ve gürültüden ayrıştırılması için tasarlanmış bir dizi artık bloktan (residual block) oluşmaktadır. Bu bloklar, genişlemeli evrişim (dilated convolution) operasyonlarından yararlanarak, sinyaldeki uzun vadeli bağımlılıkların yakalanmasını sağlamaktadır. Bu mimari, özellikle DOSE (Diffusion-based Outlier-aware Speech Enhancement)[1] çerçevesinin temel prensiplerini entegre etmektedir. Modelin adaptif kapasitesini sağlayan kritik bir bileşen, gürültü azaltma sürecinin mevcut aşamasını temsil eden “diffusion step” bilgisini alan ve bu bilgiyi ağırlık iç katmanlarına ileten difüzyon gömme (diffusion embedding) katmanıdır. Bu entegrasyon sayesinde model, aşırı temizlemeyi önleyen Diffusion Dropout ve gürültü seviyesine göre çıktığı dinamik olarak ayarlayan Adaptive Prior mekanizmaları aracılığıyla her adımda daha bilinçli kararlar alabilmektedir. Bu mekanizmaların temel çalışma prensipleri Şekil 2’de gösterilmiştir.



Şekil 2: Dropout ve Adaptive prior mekanizmaları^[1]

D. Eğitim Süreci ve Optimizasyon

Modelin eğitimi ve en iyi performansı sergileyecek hiperparametrelerin belirlenmesi, sistematik bir optimizasyon süreciyle gerçekleştirilmiştir. Modelin eğitim süreci yönetmek için yaygın olarak kullanılan ve etkili bir yakınsama sağlayan Adam optimizasyon algoritması tercih edilmiştir. Modelin tahminleri ile gerçek temiz ses sinyalleri arasındaki farkı en aza indirmek amacıyla ise Ortalama Karesel Hata (Mean Squared Error - MSE)[16] kayıp fonksiyonu kullanılmıştır. Eğitim süresini hızlandırmak ve GPU bellek kullanımı optimize etmek amacıyla FP16 (yarım duyarlılık kayan nokta)[17] hassasiyeti kullanılmıştır. Bu donanımsal optimizasyonun yanı sıra, model ağırlıklarının daha stabil bir şekilde güncellenmesi ve genelleme performansının artırılması için bir optimizasyon tekniği olan EMA (exponential Moving Average)[18] kullanılmıştır. EMA, model ağırlıklarının geçmiş adımlardaki ağırlıklarının bir ortalaması alınarak daha yumuşak ve kararlı bir versiyonunu oluşturur.

E. Değerlendirme Metrikleri

Modelin performansı, temizlenmiş sesin hem kalitesini hem de anlaşılabilirliğini nesnel olarak ölçen bir dizi standart metrik kullanılarak değerlendirilmiştir. Bu metrikler, modelin gürültü engelleme yeteneğini çok yönlü bir şekilde analiz etmeyi mümkün kılmıştır.

- **PESQ (Perceptual Evaluation of Speech Quality)[14] :** Konuşma kalitesinin insan algısına en yakın şekilde değerlendirilmesini sağlayan bir metriktir. PESQ, 1 (en kötü) ile 4.5 (en iyi)


arasında bir skorla temizlenmiş konuşmanın algılanan kalitesini ölçer

- STOI (Short Time Objective Intelligibility)[15] : Bu metrik, temizlenmiş konuşmanın anlaşılabilirliğini, yani gürültü içinden konuşmanın ne kadar net bir şekilde anlaşılabilirliğini ölçer. STOI skoru, 0 ile 1 arasında değişir; 1'e yakın değerler yüksek anlaşılabilirliği gösterir.
- SSNR (Segmental Signal-to-Noise Ratio) : Ses sinyalinin gürültüye göre kalitesini parçasal olarak ölçer. SSNR değeri ne kadar yüksek olursa, modelin gürültüyü o kadar başarılı bir şekilde bastırdığı ve sinyali koruduğu anlaşılır.
- CSIG (Signal Distortion) : Temizlenmiş sinyalin orijinal temiz sinyale ne kadar benzediğini değerlendirir. Bu metrik, 1 (en kötü) ile 5 (en iyi) arasında bir skalada skorlanır.
- CBAK (Composite Background Noise Quality): Kalan arka plan gürültüsünün algısal kalitesini değerlendirir. CBAK skoru, 1 ile 5 arasında bir skalada olup, temizlenmiş seste kalan gürültünün ne kadar rahatsız edici veya yapay olduğunu gösterir.
- COVL (Composite Overall Quality) : Hem sinyal kalitesinin (CSIG) hem de arka plan gürültüsünün kalitesini (CBAK) hesaba katan genel kalite skorudur. COVL skoru, 1 ile 5 arasında olup, modelin gürültü engelleme performansını toplu olarak yansıtır.

IV. DENEYLER

Modelin eğitimi, değerlendirilmesi ve hiperparametre optimizasyonu, Google Colaboratory (Google Colab) bulut tabanlı platform üzerinden gerçekleştirilmiştir. Bu platform, projenin yüksek performans hesaplama gereksinimlerini karşılamak amacıyla NVIDIA A100 grafik işlem biriminden (GPU) faydalanmıştır. Kullanılan donanım, modelin büyük veri setleri üzerinde verimli bir şekilde eğitilmesine olanak tanımıştır.


Yazılım ortamı, Python programlama dili üzerine kurulmuştur. Derin öğrenme modeli, PyTorch kütüphanesi kullanılarak geliştirilmiş, veri işleme ve manipülasyonu için ise NumPy ve Librosa gibi standart bilimsel kütüphanelerden yararlanılmıştır. Hiperparametre optimizasyonu ve deney takibi için ise Weights & Biases (WandB) platformu entegre edilmiştir.



Şekil 3: P.56 veri seti üzerinde hiperparametrelerin doğrulama kaybı üzerindeki etkileşimini gösteren paralel koordinat grafiği

Modelin performansını sentetik olarak oluşturulan P.56 veri seti üzerinde ayrıntılı bir şekilde değerlendirilmiştir. Bu

veri setindeki sweep deneyleri, Şekil 3'te de detayları görüldüğü gibi, öğrenme oranı (learning rate), dropout oranı (dropout_rate) ve ema_decay parametrelerinin farklı kombinasyonlarının model performansı üzerindeki etkilerini sistematik bir şekilde ölçmek amacıyla yürütülmüştür. Elde edilen sonuçlar, modelin karmaşık gürültü ortamlarında en yüksek performansı gösterecek en iyi hiperparametre kombinasyonunun belirlenmesini sağlamıştır.



Şekil 4: LKFS veri seti üzerinde hiperparametrelerin doğrulama kaybı üzerindeki etkileşimini gösteren paralel koordinat grafiği

Modelin performansı, LKFS veri setini kullanarak da değerlendirilmiştir. Bu veri setindeki sweep deneyleri, Şekil 4'te de detayları görüldüğü gibi, ema_decay değerinin 0.999 ve 0.99 olarak ayarlandığı iki farklı senaryoda yürütülmüştür. Bu deneyler, öğrenme oranı ve dropout oranı gibi anahtar hiperparametrelerin en uygun değerlerini bulmaya odaklanmıştır. Yapılan analizler, modelin bu parametrelerin belirli bir kombinasyonunda en düşük kayıp değerlerine ulaştığını göstermiştir.

Deney Senaryosu	PESQ	STOI	SSNR	CSIG	CBAK	COVL
P56 step1: 45 - step2: 5	2,5356	0,8518	4,2494	3,7961	2,8872	3,1425
P56 step1: 40 - step2: 10	2,4888	0,8493	4,2170	3,6565	2,8597	3,0474
P56 step1: 35 - step2: 15	2,4726	0,8483	4,2000	3,5994	2,8514	3,0102
P56 step1: 30 - step2: 20	2,6789	0,8630	4,2958	3,7274	2,9553	3,1778
LKFS step1: 45 - step2: 5	2,5382	0,8542	4,3201	3,8064	2,894	3,1495
LKFS step1: 40 - step2: 10	2,4909	0,8516	4,2895	3,6701	2,8664	3,0554
LKFS step1: 35 - step2: 15	2,4731	0,8506	4,2712	3,6127	2,857	3,0172
LKFS step1: 30 - step2: 20	2,6774	0,8652	4,3695	3,7401	2,9602	3,1834

Tablo 5: Farklı veri setleri ve step1, step2 kombinasyonları için değerlendirme metrikleri sonuçları

Hiperparametre optimizasyonunun yanı sıra, modelin çıkarım (inference) sürecini doğrudan etkileyen difüzyon adımları ve Adaptive Prior mekanizmasının parametreleri de detaylı olarak değerlendirilmiştir. Özellikle step1 ve step2 parametreleri, modelin gürültü engelleme sürecinde ne zaman ve hangi seviyede Adaptive Prior devreye alacağını belirlemiştir. Bu parametrelerin farklı kombinasyonlarının P.56 ve LKFS veri setleri üzerindeki etkilileri, Tablo 5'te gösterilmiştir. Bu parametrelerin doğru şekilde ayarlanması, nihai ses kalitesinin doğrudan etkilediği için deneysel süreçte kritik yol oynamıştır.

V. SONUÇLAR

Geliştirilen difüzyon tabanlı gürültü engelleme modelinin performansı, farklı Adaptive Prior parametre kombinasyonları kullanılarak P.56 ve LKFS veri setleri üzerinde detaylı olarak değerlendirilmiştir. Elde edilen nicel sonuçlar, modelin gürültü engelleme görevini etkin bir şekilde yerine getirdiği ortaya koymaktadır. Özellikle P.56 veri setinde step1: 30 – step2: 20 kombinasyonu 0.8630'luk en yüksek STOI skoruyla, LKFS veri setinde ise step1: 40 – step2 : 10 kombinasyonu 0.8655'lik STOI skoruyla konuşma

anlaşılabilirliğinin en üst düzeye çıkarmıştır. PESQ metrikleri de modelin başarısını desteklemektedir. Bu bulgular modelin karmaşık gürültüyü azaltmakla kalmayıp, aynı zamanda insan kulağı tarafından algılanan konuşma kalitesini ve anlaşılabilirliğini de önemli ölçüde artırdığını göstermektedir.

Ancak, nicel metriklerde elde edilen bu başarılı sonuçlara rağmen, modelin çıktıları pratik dinleme testlerinde önemli problemlere sahiptir. Özellikle, gürültüyü azaltmak yerine, bazen ses sinyali yeni ve rahatsız edici gürültü sinyalleri eklediği gözlenmiştir. Bu durum, modelin arka plan gürültüsünü tamamen bastırmakta ve sesin doğallığını iyileştirmekte yetersiz kaldığını göstermektedir.

Table 1: Comparison of different diffusion enhancement methods.

Method	Year	Efficiency	Dataset	STOI(%)↑	PESQ↑	CSIG↑	CBARK↑	COVL↑
Unprocessed	—	—	—	92.1	1.97	3.35	2.44	2.63
DiffWave	2021	1 step (dis)	VB	93.3	2.51	3.72	3.27	3.11
DiffuSE	2021	6 steps	VB	93.5 ^{+0.20} _{+0.05}	2.39 ^{-0.12} _{+0.01}	3.71 ^{-0.01} _{+0.01}	3.04 ^{-0.23} _{+0.01}	3.03 ^{-0.08} _{+0.01}
CDiffuSE	2022	6 steps	VB	93.7 ^{+0.40} _{+0.05}	2.43 ^{-0.05} _{+0.01}	3.77 ^{+0.05} _{+0.01}	3.09 ^{-0.15} _{+0.01}	3.09 ^{-0.02} _{+0.01}
SGMSE	2022	50 steps	VB	93.3 ^{+0.00} _{+0.01}	2.34 ^{-0.17} _{+0.01}	3.69 ^{-0.03} _{+0.01}	2.90 ^{-0.35} _{+0.01}	3.00 ^{-0.11} _{+0.01}
DR-DiffuSE	2023	6 steps	VB	92.9 ^{+0.04} _{+0.01}	2.50 ^{-0.01} _{+0.01}	3.68 ^{-0.04} _{+0.01}	3.27 ^{-0.00} _{+0.01}	3.08 ^{-0.03} _{+0.01}
DOSE	—	2 steps	VB	93.6 ^{+0.06} _{+0.05}	2.56 ^{-0.05} _{+0.01}	3.83 ^{+0.11} _{+0.01}	3.27 ^{-0.00} _{+0.01}	3.19 ^{-0.06} _{+0.01}
Unprocessed	—	—	—	71.5	1.21	2.18	1.97	1.62
DiffWave	2021	1 step (dis)	CHIME-4	72.3	1.22	2.21	1.95	1.63
DiffuSE	2021	6 steps	CHIME-4	83.7 ^{+11.4} _{+0.05}	1.59 ^{+0.36} _{+0.01}	2.91 ^{+0.70} _{+0.01}	2.19 ^{+0.24} _{+0.01}	2.19 ^{+0.56} _{+0.01}
CDiffuSE	2022	6 steps	CHIME-4	82.8 ^{+10.5} _{+0.05}	1.58 ^{+0.36} _{+0.01}	2.88 ^{+0.67} _{+0.01}	2.15 ^{+0.01} _{+0.01}	2.18 ^{+0.55} _{+0.01}
SGMSE	2022	50 steps	CHIME-4	84.5 ^{+10.05} _{+0.05}	1.57 ^{+0.34} _{+0.01}	2.92 ^{+0.71} _{+0.01}	2.18 ^{+0.23} _{+0.01}	2.18 ^{+0.55} _{+0.01}
DR-DiffuSE	2023	6 steps	CHIME-4	77.6 ^{+10.06} _{+0.05}	1.29 ^{+0.07} _{+0.01}	2.40 ^{+0.18} _{+0.01}	2.04 ^{+0.02} _{+0.01}	1.78 ^{+0.15} _{+0.01}
DOSE	—	2 steps	CHIME-4	86.6 ^{+10.05} _{+0.05}	1.52 ^{+0.30} _{+0.01}	2.71 ^{+0.61} _{+0.01}	2.19 ^{+0.01} _{+0.01}	2.06 ^{+0.43} _{+0.01}

Tablo 6 : Ana Referans makalenin metrik sonuçları^[1]

Tablo 6’da gösterilen sonuçlar incelendiğinde, geliştirilen modelin en iyi performans gösteren kombinasyonlarının, özellikle STOI ve diğer metrikler açısından, referans makaledeki DOSE[1] modelinin sonuçlarının gerisinde kaldığı görülmektedir. PESQ değerleri benzer bir aralıkta görünse de, diğer metriklerde makaledeki değerlerin daha yüksek olması, referans modelin daha kapsamlı bir performans üstünlüğü sağladığını göstermektedir. Bu durum, modelimizin hala iyileştirme potansiyeli olduğunu göstermektedir.

REFERENCES

[1] Tai, W., Lei, Y., Zhou, F., Trajcevski, G., & Zhong, T. (2023). DOSE: Diffusion dropout with adaptive prior for speech enhancement. *Advances in Neural Information Processing Systems*, 36, 40272-40293.

[2] Richter, J., Wu, Y. C., Krenn, S., Welker, S., Lay, B., Watanabe, S., ... & Gerkmann, T. (2024). EARS: An anechoic fullband speech dataset benchmarked for speech enhancement and dereverberation. *arXiv preprint arXiv:2406.06185*.

[3] INSTALLATIONS, T., & LINE, L. ITU-Tp. 561.

[4] Pestana, P. D., Reiss, J. D., & Barbosa, A. (2013, May). Loudness measurement of multitrack audio content using modifications of ITU-

R BS. 1770. In *Audio Engineering Society Convention 134*. Audio Engineering Society.

[5] Ho, J., Jain, A., & Abbeel, P. (2020). Denoising diffusion probabilistic models. *Advances in neural information processing systems*, 33, 6840-6851.

[6] Kong, Z., Ping, W., Huang, J., Zhao, K., & Catanzaro, B. (2020). Diffwave: A versatile diffusion model for audio synthesis. *arXiv preprint arXiv:2009.09761*.

[7] Tai, W., Zhou, F., Trajcevski, G., & Zhong, T. (2023, June). Revisiting denoising diffusion probabilistic models for speech enhancement: Condition collapse, efficiency and refinement. In *Proceedings of the AAAI conference on artificial intelligence* (Vol. 37, No. 11, pp. 13627-13635).

[8] Lu, Y. J., Wang, Z. Q., Watanabe, S., Richard, A., Yu, C., & Tsao, Y. (2022, May). Conditional diffusion probabilistic model for speech enhancement. In *ICASSP 2022-2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)* (pp. 7402-7406). Ieee.

[9] Serrà, J., Pascual, S., Pons, J., Araz, R. O., & Scaini, D. (2022). Universal speech enhancement with score-based diffusion. *arXiv preprint arXiv:2206.03065*.

[10] Veaux, C., Yamagishi, J., & King, S. (2013, November). The voice bank corpus: Design, collection and data analysis of a large regional accent speech database. In *2013 international conference oriental COCOSDA held jointly with 2013 conference on Asian spoken language research and evaluation (O-COCOSDA/CASLRE)* (pp. 1-4). IEEE.

[11] https://huggingface.co/datasets/issai/Turkish_Speech_Corpus/tree/main

[12] <https://www.kaggle.com/datasets/jweiqi/voicebank-demand-16k>

[13] ITU-T, P. (1993). Objective measurement of active speech level. *ITU-T Recommendation*.

[14] Rix, A. W., Beerends, J. G., Hollier, M. P., & Hekstra, A. P. (2001, May). Perceptual evaluation of speech quality (PESQ)-a new method for speech quality assessment of telephone networks and codecs. In *2001 IEEE international conference on acoustics, speech, and signal processing. Proceedings (Cat. No. 01CH37221)* (Vol. 2, pp. 749-752). IEEE.

[15] Taal, C. H., Hendriks, R. C., Heusdens, R., & Jensen, J. (2010, March). A short-time objective intelligibility measure for time-frequency weighted noisy speech. In *2010 IEEE international conference on acoustics, speech and signal processing* (pp. 4214-4217). IEEE.

[16] Hodson, T. O., Over, T. M., & Foks, S. S. (2021). Mean squared error, deconstructed. *Journal of Advances in Modeling Earth Systems*, 13(12), e2021MS002681.

[17] Micikevicius, P., Narang, S., Alben, J., Diamos, G., Elsen, E., Garcia, D., ... & Wu, H. (2017). Mixed precision training. *arXiv preprint arXiv:1710.03740*.

[18] Haynes, D., Corns, S., & Venayagamoorthy, G. K. (2012, June). An exponential moving average algorithm. In *2012 IEEE congress on evolutionary computation* (pp. 1-8). IEEE.